

SISTEM REKOMENDASI FILM MENGGUNAKAN DATA USER-END DAN KNOWLEDGE GRAPH CONVOLUTIONAL NETWORK

Diajukan untuk Memenuhi Salah Satu Syarat
Matakuliah Tugas Akhir 1
Jenjang Strata 1 pada Program Studi Informatika
Universitas Jenderal Achmad Yani

Oleh:

Nama : Muhammad Rizki Yanuar

NIM : 3411211062

Pembimbing 1

Fajri Rakhmat Umbara, S.T., M.T

NID: 412185888

Pembimbing 2

Agus Komarudin, S.Kom, M.T.

NID: 412175878



PROGRAM STUDI TEKNIK INFORMATIKA
FAKULTAS SAINS DAN INFORMATIKA
UNIVERSITAS JENDERAL ACHMAD YANI

2025

HALAMAN PENGESAHAN

**SISTEM REKOMENDASI FILM MENGGUNAKAN DATA USER-END
DAN KNOWLEDGE GRAPH CONVOLUTIONAL NETWORK**

Cimahi, 2025

Oleh

Muhammad Rizki Yanuar

NIM.3411211062

Menyetujui


Pembimbing 1



Fajri Rakhmat Umbara, S.T., M.T.

NID. 412185888

Pembimbing 2



Agus Komarudin, S.Kom, M.T.

NID. 412175878



LEMBAR PERNYATAAN KEASLIAN PENULISAN SKRIPSI

Saya yang bertandatangan dibawah ini, dengan ini menyatakan bahwa penulisan skripsi yang telah saya susun dengan judul seperti berikut:

**“SISTEM REKOMENDASI FILM MENGGUNAKAN DATA USER-END
DAN KNOWLEDGE GRAPH CONVOLUTIONAL NETWORK”**

Merupakan hasil karya saya sendiri. Berkas beserta program yang telah dibuat merupakan hasil pekerjaan saya sepenuhnya. Ide, pendapat atau materi yang berasal dari sumber lain telah dikutip dengan penulisan referensi yang sesuai dengan aturan dan bersifat baku.

Demikian pernyataan ini telah saya buat.

Cimahi, 2025

Muhammad Rizki Yanuar

NIM. 3411 21 1062

ABSTRAK

Penelitian ini bertujuan untuk mengatasi permasalahan kurang akuratnya sistem rekomendasi film yang dihadapi oleh pengguna platform digital dalam menemukan film yang sesuai dengan preferensi mereka. Latar belakang penelitian ini didasarkan pada kelemahan pendekatan sistem rekomendasi tradisional, seperti Collaborative Filtering, yang hanya mengandalkan interaksi user-item tanpa mempertimbangkan informasi kontekstual dan relasional tambahan yang dimiliki oleh user dan item. Akibatnya, sistem rekomendasi tidak mampu menyajikan rekomendasi yang bersifat personalisasi dan relevan secara optimal. Permasalahan ini penting untuk dipecahkan karena dapat memengaruhi kualitas pengalaman pengguna secara langsung, serta berdampak terhadap keterlibatan dan retensi pengguna dalam jangka panjang. Metode penelitian yang digunakan dalam analisis dan perancangan adalah pendekatan kuantitatif dengan eksperimen komputasi berbasis Graph Convolutional Network (GCN) yang memanfaatkan struktur knowledge graph sebagai representasi relasi antar entitas dalam sistem rekomendasi. Knowledge graph dibentuk berdasarkan data yang diperoleh dari dataset MovieLens 1M, yang terdiri dari tiga file utama: movies, ratings, dan users. Dataset ini mencakup informasi film (judul dan genre), interaksi pengguna (rating terhadap film), serta profil pengguna (gender, usia, pekerjaan). Setelah dilakukan penggabungan ketiga dataset berdasarkan kesamaan ID pengguna dan ID film, terbentuk total 1.000.209 data interaksi dengan delapan atribut. Tahapan pelaksanaan penelitian meliputi preprocessing data, label encoding atribut kategorik seperti gender, pembentukan knowledge graph dengan node-node seperti User, Movie, Genre, Gender, Age, dan Occupation, serta pembentukan triplet hubungan antar entitas dalam format (head, relation, tail). Triplet ini digunakan sebagai dasar relasi dalam graph, seperti user memberi rating ke film, film memiliki genre tertentu, atau user memiliki pekerjaan tertentu. Selanjutnya dilakukan pembentukan embedding awal berdimensi 64 yang diinisialisasi secara acak untuk setiap node, yang kemudian diperbarui selama pelatihan menggunakan teknik message passing dan importance sampling. Teknik importance sampling diterapkan untuk memilih tetangga (neighbors) yang paling relevan dalam proses agregasi pesan antar node. Proses ini mencakup perhitungan skor relevansi berdasarkan dot product antar embedding, normalisasi skor menggunakan softmax, dan pemilihan top-k tetangga terpenting untuk setiap jenis relasi. Message passing dilakukan dengan pendekatan sum aggregation berbobot, sehingga informasi dari tetangga yang lebih relevan mendapatkan pengaruh yang lebih besar dalam pembaruan embedding node pusat. Pemecahan masalah dilakukan melalui pelatihan model GCN berbasis knowledge graph dengan importance sampling dibandingkan dengan pendekatan uniform sampling. Model diuji dengan metrik evaluasi sistem rekomendasi, yaitu Precision@K, Recall@K, Normalized Discounted Cumulative Gain (NDCG@K), dan Area Under Curve (AUC). Hasil pelatihan menunjukkan bahwa importance sampling mampu meningkatkan performa model secara signifikan. Precision@10 pada importance sampling mencapai 0.50, dibandingkan hanya 0.28 pada uniform sampling. Recall@10 menunjukkan hasil hampir sempurna, sebesar 1.000, dan NDCG@10 mencapai 0.96, AUC mencapai 0.8636

lebih tinggi dibandingkan pada uniform sampling. Selain itu, importance sampling menunjukkan AUC yang lebih stabil dan tinggi selama 10 epoch pelatihan, serta memiliki kemampuan lebih baik dalam membedakan item relevan dan tidak relevan. Penelitian ini juga melakukan eksperimen hyperparameter tuning dengan variasi nilai learning rate dan ukuran embedding. Konfigurasi terbaik ditemukan pada kombinasi learning rate 0.001, embedding size 32, dan jumlah epoch sebanyak 20. Hasil validasi pada konfigurasi ini menunjukkan peningkatan nilai evaluasi, dengan NDCG@K mencapai 0.9719 dan AUC sebesar 0.8798 pada data validasi. Pengujian pada data testing juga menunjukkan performa yang serupa dengan validasi, menandakan bahwa model tidak mengalami overfitting dan dapat diandalkan pada data baru.

Kata Kunci: Knowledge Graph, Graph Convolutional Network, Sistem Rekomendasi Film, Cold Start, Sparsity, Data User-End

KATA PENGANTAR

Puji dan syukur saya panjatkan ke hadirat Tuhan Yang Maha Esa, karena atas rahmat dan karunia-Nya, saya dapat menyusun proposal Tugas Akhir ini sebagai salah satu syarat akademik dalam menyelesaikan studi di program ini. Proposal ini disusun sebagai langkah awal dalam penelitian yang akan saya lakukan guna menyelesaikan Tugas Akhir. Dalam proses penyusunan proposal ini, saya memperoleh banyak wawasan dan pemahaman baru dari berbagai referensi serta bimbingan dari dosen pembimbing. Oleh karena itu, saya ingin mengucapkan terima kasih yang sebesar-besarnya kepada dosen pembimbing yang telah memberikan arahan dan masukan yang sangat berharga. Tak lupa, saya juga menyampaikan apresiasi kepada teman-teman dan keluarga yang selalu memberikan dukungan moral dan motivasi dalam menyelesaikan tahap awal penelitian ini. Saya menyadari bahwa dalam penyusunan proposal ini masih terdapat banyak kekurangan. Oleh karena itu, saya sangat mengharapkan saran dan kritik yang membangun agar penelitian ini dapat berkembang lebih baik dan memberikan kontribusi yang berarti. Semoga proposal ini dapat menjadi landasan yang kuat dalam pelaksanaan penelitian Tugas Akhir dan bermanfaat bagi pengembangan ilmu pengetahuan di bidang yang saya tekuni. Demikian pengantar ini saya sampaikan. Semoga penelitian ini dapat berjalan dengan lancar dan memberikan hasil yang maksimal.

Hormat Kami,

Muhammad Rizki Yanuar

3411211062

Cimahi, 18 Februari 2025

DAFTAR ISI

HALAMAN PENGESAHAN.....	i
LEMBAR PERNYATAAN KEASLIAN PENULISAN SKRIPSI	ii
ABSTRAK	iii
KATA PENGANTAR.....	v
DAFTAR ISI	vi
BAB I PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah	3
1.3 Batasan Masalah.....	4
1.4 Tujuan Penelitian.....	4
1.5 Metode Penelitian.....	4
1.5.1 Teknik Pengumpulan Data	4
1.5.2 Teknik Penerapan Metode atau konsep.....	4
1.6 Sistematika Penulisan	5
BAB II TINJAUAN PUSTAKA	6
2.1 Data Mining	6
2.2 Sistem Rekomendasi	6
2.3 Knowledge Graph	6
2.4 Interaksi pengguna-item.....	7
2.5 Graph Convolutional Network.....	7
2.6 Importance sampling (IS).....	7
2.7 Message Passing & Sum Aggregation	7

2.8	Hyperparameter Tuning	8
2.9	Metrik Evaluasi	8
2.9.1	Recall@K	8
2.9.2	Precision@K	8
2.9.3	Normalized Discounted Cumulative Gain (NDGC@K).....	9
2.9.4	AUC (Area Under Curve)	9
2.10	Output.....	9
2.11	Penelitian Terdahulu.....	9
BAB III	METODOLOGI PENELITIAN.....	11
3.1	Metode Penelitian.....	11
3.2	Pendekatan Penelitian	11
3.3	Dataset.....	12
3.4	Preprocessing Data.....	13
3.4.1	Penggabungan Dataset	13
3.4.2	Label Encoding	13
3.5	Knowledge Graph	14
3.6	Representasi Node.....	14
3.7	Data Interaksi User-Item	15
3.8	Pembentukan Triplet	15
3.9	Graph Convolutional Network.....	16
3.9.1	Embedding Awal	16
3.9.2	Importance Sampling	16
3.9.3	Message Passing & Sum Aggregation	17
3.9.4	Prediksi.....	17
3.10	Metrik Evaluasi	18

3.10.1	Recall@K.....	18
3.10.2	Precision@K	18
3.10.3	NDCG@K.....	18
3.10.4	AUC	19
BAB IV	HASIL DAN PEMBAHASAN	20
4.1	Hasil	20
4.1.1	Dataset.....	20
4.1.2	Penggabungan Dataset	21
4.1.3	Label Encoding	22
4.1.4	Knowledge Graph	22
4.1.5	Splitting Dataset.....	23
4.1.6	Graph Convolutional Network.....	23
4.1.7	Pelatihan Model	25
4.1.8	Hyperparameter.....	28
4.1.9	Pelatihan Ulang	28
4.1.10	Test Model.....	29
BAB V	KESIMPULAN DAN SARAN.....	30
5.1	Saran.....	30
5.2	Saran.....	31
DAFTAR PUSTAKA		32

DAFTAR GAMBAR

Gambar 1 Metode Penelitian.....	11
Gambar 2 Arsitektur Knowledge Graph	14
Gambar 3 Data Movies	20
Gambar 4 Data Rating.....	20
Gambar 5 Data Users	21
Gambar 6 Penggabungan Dataset	21
Gambar 7 Label Encoding	22
Gambar 8 Metrik Evaluasi	27
Gambar 9 Pelatihan ulang	28

DAFTAR TABEL

Tabel 1 Hyperparameter Tuning.....	8
Tabel 2 Atribut User	12
Tabel 3 Atribut Film	12
Tabel 4 Rating Film.....	13
Tabel 5 Triplet Hubungan.....	23
Tabel 6 Parameter Model Awal	25
Tabel 7 Perbandingan Waktu Komputasi Training.....	26
Tabel 8 Hyperparameter Model	28

BAB I PENDAHULUAN

1.1 Latar Belakang

Dalam industri film, sistem rekomendasi sangat penting untuk membantu pengguna menemukan film yang sesuai dengan preferensi mereka. Dengan dirilisnya ribuan film setiap tahun, menimbulkan tantangan besar yaitu bagaimana menyaring pilihan sehingga pengguna dengan mudah menemukan film yang cocok bagi mereka. Meskipun telah digunakan secara luas, metode tradisional seperti *collaborative filtering* dan *content-based filtering* sering kali menghadapi masalah *sparsity* dan *cold start* [1], dikarenakan data interaksi pengguna dengan item terbatas atau tidak ada untuk pengguna baru bahkan sampai menyebabkan risiko overfitting pada model [2].

Untuk mengatasi masalah ini, penelitian telah beralih ke pendekatan *deep learning*, termasuk penggunaan *Knowledge Graph Convolutional Networks* (KGCN). *Knowledge Graph* (KG) merupakan sebuah grafik yang menyimpan informasi terarah dengan simpul yang mewakili entitas (seperti pengguna, item atau atribut) dan tepi yang mewakili hubungan antar entitas. Salah satu keunggulan KG adalah kemampuan dalam menghubungkan berbagai atribut dan informasi yang relevan untuk pengguna dan item. *Graph Convolutional Network* (GCN) merupakan metode yang dirancang untuk bekerja dengan data yang terstruktur dalam bentuk graf. Pada GCN terdapat fitur utama yaitu kemampuan dalam mengagregasi dan menggabungkan informasi dari tetangga terdekat, desain semacam ini memiliki 2 keuntungan: (1) Struktur kedekatan lokal secara efektif dicatat dan disimpan di setiap entitas melalui metode agregasi. (2) Tetangga diberi bobot berdasarkan skor yang bergantung pada pengguna tertentu dan hubungan antar entitas. Skor ini menggambarkan informasi konten dari KG serta minat relasional pengguna itu sendiri [3]. Namun penerapan KG pada sistem rekomendasi memiliki beberapa tantangan seperti masalah dimensi yang tinggi dan heterogenitas yang disebabkan adanya berbagai macam entitas dan hubungan yang terbentuk [3]. Selain itu pada GCN juga mengalami masalah jika berurusan dengan graph

heterogenitas yang berskala besar, dimana model GCN umumnya mengalami kompleksitas waktu yang mahal dan ukuran memori yang besar dikarenakan jumlah nodes dan interaksi yang sangat besar, sehingga untuk mengurangi waktu komputasi dan penggunaan memori yang besar maka diterapkan metode sampling pada graph heterogenitas, dimana teknik sampling ini akan mengambil nodes yang lebih kecil pada *layer* tertentu tetapi representatif dari distribusi yang memberikan bobot lebih pada *layer* tertentu [2]. Berbagai penelitian telah dilakukan dalam pengembangan sistem rekomendasi yang memanfaatkan data item-end dan user-item dengan menggunakan berbagai metode.

Pada penelitian [3] penggunaan KGCN dengan memanfaatkan data item-ends dan menggunakan *uniformly sampling fixed-size neighborhood* untuk mengatasi jumlah nodes tetangga yang sangat besar, yang menghasilkan rekomendasi berdasarkan atribut-atribut item dan mengurangi waktu komputasi karena menentukan jumlah nodes tetangga yang akan diambil. Penelitian ini menunjukkan bahwa KGCN dapat efektif dalam mengidentifikasi keterkaitan antar item dari atribut yang terdapat dalam *Knowledge Graph* dan *uniformly sampling fixed-size neighborhood* menunjukkan peningkatan rata-rata AUC 4,4% karena dapat menangkap informasi yang jauh lebih banyak. Meskipun penelitian ini memberikan hasil signifikan terhadap pengembangan sistem rekomendasi berbasis item, masih terdapat celah dalam pemanfaatan data user-end dan teknik sampling. Penelitian lebih lanjut diperlukan untuk mengeksplorasi bagaimana umpan balik pengguna, baik bersifat eksplisit maupun implisit dapat diintegrasikan ke dalam model KGCN dan bagaimana teknik *importance sampling* dapat meningkatkan akurasi model, dengan demikian sistem rekomendasi tidak hanya bergantung pada atribut item tetapi juga mempertimbangkan preferensi dan pengalaman pengguna serta menangkap informasi yang jauh lebih relevan ketika pemilihan nodes tetangga. Pada penelitian [4] penggunaan sistem rekomendasi hybrid yang menggabungkan *Collaborative Filtering*, *Content-Based Filtering*, dan teknik *Self-Organizing* (SOM) dengan memanfaatkan data user-item sebagai dasar untuk mengembangkan model rekomendasi. Kemudian pendekatan hybrid ini memanfaatkan metode *weighted* dengan menggabungkan skor dari collaborative

filtering dan content-based filtering untuk menghasilkan satu rekomendasi dan *Feature Augmentation* dengan memanfaatkan output dari hasil rekomendasi *collaborative dan content-based* kemudian menjadikan hasil rekomendasi tersebut sebagai informasi tambahan dalam menciptakan model rekomendasi. Penelitian ini menyarankan penerapan *Deep Learning* seperti *Graph Neural Network* (GNN) untuk menangkap pola interaksi yang lebih kompleks, pengembangan strategi untuk menangani masalah cold start bagi pengguna baru atau item baru, dan mengintegrasikan data user-end untuk mengeksplorasi bagaimana umpan balik eksplisit dan implisit dari pengguna dapat meningkatkan akurasi rekomendasi.

Penelitian ini berfokus pada mengatasi tantangan utama dalam sistem rekomendasi film, seperti masalah sparsity, cold-start, dan efisiensi komputasi. Dengan mengintegrasikan data user-end, termasuk umpan balik eksplisit dan implisit, ke dalam Knowledge Graph Convolutional Network (KGCN), sistem rekomendasi dapat menangkap preferensi pengguna secara lebih personalisasi, tidak hanya bergantung pada atribut item. Selain itu, teknik importance sampling diterapkan untuk mengoptimalkan pemilihan nodes tetangga dalam Knowledge Graph, memastikan hanya informasi yang relevan diambil, sehingga mengurangi beban komputasi tanpa mengorbankan akurasi rekomendasi. Performa model yang diusulkan akan dievaluasi dan dibandingkan dengan metode *uniform sampling* mengukur peningkatan dalam akurasi, relevansi rekomendasi, dan efisiensi waktu komputasi.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah dijelaskan, rumusan masalah dalam penelitian ini adalah:

Apakah penerapan teknik *importance sampling* pada model *Knowledge Graph Convolutional Network* (KGCN) dapat mengurangi waktu komputasi pelatihan model dan meningkatkan relevansi rekomendasi dibandingkan dengan penggunaan teknik *uniform sampling*?

1.3 Batasan Masalah

Penelitian ini hanya menggunakan dataset dari platform MovieLens tanpa menggabungkan data diluar platform tersebut, dan tidak membuat aplikasi sistem rekomendasi

1.4 Tujuan Penelitian

Tujuan dari penelitian ini adalah untuk mengevaluasi kinerja model rekomendasi film berbasis KGCN dengan penerapan teknik importance sampling, serta membandingkannya dengan teknik uniform sampling, dengan mempertimbangkan metrik evaluasi seperti precision@k , recall@k , NDCG@k , AUC, dan waktu komputasi selama training.

1.5 Metode Penelitian

1.5.1 Teknik Pengumpulan Data

Pengambilan data diambil dari website movielens, dimana data yang diambil memiliki 100.000 data rating. Dataset terbagi menjadi tiga bagian:

- Data Pengguna: Berisi demografi user,
- Data film: Berisi genre untuk film
- Data rating: Berisikan skala rating 1-5 yang diberikan kepada film yang ditonton.

1.5.2 Teknik Penerapan Metode atau konsep

Metode yang digunakan berupa label encoding dalam merubah data yang bersifat kategorik menjadi bentuk numerik, selanjutnya dari tiga data yang terpisah akan dilakukan penggabungan dataset untuk mendapatkan informasi yang lebih jelas.

Setelah itu dilakukan pembuatan *knowledge graph* untuk membentuk graph hubungan antar node kemudian akan dilakukan splitting data menjadi 3 yaitu *data train*, *data validation* dan *data test* dengan pembagian 80:10:10.

Setelah dilakukan splitting data, pada model *graph convolutional network* dibuat nilai embedding awal pada masing-masing *nodes*, kemudian diterapkan *importance sampling* untuk menentukan mana nodes yang memiliki informasi paling relevan berdasarkan bobot relasi antar node, kemudian embedding node pusat akan

diperbarui menggunakan *message passing* dimana informasi dari node tetangga akan dijumlahkan dengan informasi node pusat menggunakan *sum aggregation*, setelah itu akan dilakukan prediksi terhadap hubungan kepada node item.

1.6 Sistematika Penulisan

Sistematika penulisan yang digunakan dalam penulisan laporan tugas akhir ini yaitu sebagai berikut:

BAB 1	PENDAHULUAN
	BAB 1 menguraikan latar belakang, rumusan masalah, batasan masalah, tujuan penelitian, luaran dan manfaat penelitian, serta metodologi penelitian.
BAB 2	TINJAUAN PUSTAKA
	BAB 2 menguraikan definisi berbagai teori penunjang yang digunakan sebagai rujukan dalam penyusunan laporan.
BAB 3	ANALISIS DAN PERANCANGAN SISTEM
	BAB 3 berisi analisis dan perancangan sistem yang dikembangkan.
BAB 4	IMPLEMENTASI DAN PENGUJIAN SISTEM
	BAB 4 berisi
BAB 5	KESIMPULAN DAN SARAN
	BAB 5 berisi
DAFTAR PUSTAKA	Daftar pustaka berisi
LAMPIRAN	Lampiran berisi

BAB II TINJAUAN PUSTAKA

2.1 Data Mining

Data mining adalah kumpulan metode yang mengekstrak informasi dari basis data yang besar, digunakan untuk menemukan korelasi, karakteristik, dan tren baru, dimana informasi tersebut harus membantu dalam pengambilan keputusan [5]. Proses ini dilakukan menggunakan teknologi statistik, ML dan pengenalan pola [6][7].

2.2 Sistem Rekomendasi

Sistem rekomendasi adalah alat penyaringan informasi yang menangani masalah dengan menyediakan konten yang menarik bagi pengguna dengan cara yang personalisasi [8]. Sistem rekomendasi merupakan teknologi yang berguna untuk meringankan masalah kelebihan informasi yang diberikan kepada pengguna, dimana sistem memberikan pengguna daftar item yang direkomendasikan yang mungkin mereka sukai atau memprediksi seberapa besar mereka menyukai setiap item [9].

2.3 Knowledge Graph

Knowledge Graph (KG) diperkenalkan oleh Google pada tahun 2012 dengan tujuan untuk mencapai mesin pencari yang lebih cerdas, KG merupakan struktur data yang menyimpan informasi dalam bentuk entitas serta hubungan antar entitas. Setiap node dalam KG merepresentasikan entitas, sedangkan edge menggambarkan jenis hubungan antara dua entitas. Dalam sistem rekomendasi, KG digunakan untuk mengumpulkan informasi tambahan dan konektivitas menjadi pengetahuan yang tidak hanya bergantung pada interaksi pengguna-item sehingga informasi menjadi lebih mudah dipahami sehingga membentuk informasi yang penuh makna [1][10].

Pada dasarnya struktur KG membentuk struktur jaringan heterogen yang terdiri dari atas *node* dan *edge*, dalam konteks sistem rekomendasi *node* mencakup entitas seperti pengguna, film, *genre*, *age*, *occupation*, dan *gender*. Sementara *edge* menggambarkan hubungan antar entitas, seperti *hasGenre* (memiliki genre),

hasOccupation (memiliki pekerjaan) atau *rates* (memberi rating), dan sebuah *knowledge graph* umumnya direpresentasikan dalam bentuk (h, r, t) yang terdiri dari *head*, *relation*, *tail* [11]. Kemudian pada KG terdapat skema agregasi untuk mengintegrasikan informasi ke satu entitas yang telah terhubung ke entitas lain sebagai atributnya yang mencerminkan kemiripan konten diantara item[12].

2.4 Interaksi pengguna-item

Pada bentuk sistem rekomendasi, terdapat interaksi yang secara *implicit* diberikan oleh pengguna mengenai preferensi yang dipilih (seperti, melihat, klik, membeli, menilai). Terdapat sekumpulan pengguna dan sekumpulan item, interaksi pengguna-item tersebut disesuaikan dengan umpan balik *implicit* pengguna, di mana diberi nilai 1 yang mengindikasikan bahwa user tersebut berinteraksi dengan item, dan sebaliknya 0 yang mengindikasikan bahwa user tersebut tidak berinteraksi dengan item[3].

2.5 Graph Convolutional Network

Graph Convolutional Network (GCN) adalah jenis jaringan saraf yang dirancang untuk bekerja dengan data yang terstruktur dalam bentuk graf, memungkinkan model menangkap informasi dari *node* tetangga melalui mekanisme propagasi informasi [13].

2.6 Importance sampling (IS)

Importance Sampling merupakan teknik pengambilan sampel yang bertujuan untuk memilih *node* atau *edge* yang memiliki bobot lebih besar atau dianggap lebih penting dalam graph. Sampling ini dilakukan terhadap subset *node* atau *edge* yang memiliki informasi signifikan, sehingga proses pelatihan model menjadi lebih efisien dan akurat[2].

2.7 Message Passing & Sum Aggregation

Agregasi representasi bertujuan untuk mengumpulkan dan menggabungkan informasi dari simpul tetangga sehingga model dapat memahami pola dan ketergantungan lokal dalam graf menjadi satu vektor representasi baru. Proses ini dikenal sebagai message passing, di mana setiap node menerima "pesan" berupa

embedding dari tetangganya, kemudian mengagregasi pesan-pesan tersebut menggunakan fungsi agregasi [14] [15].

2.8 Hyperparameter Tuning

Hyperparameter tuning adalah proses dimana parameter model dilakukan penyesuaian sedemikian rupa untuk meningkatkan kinerja model. Pada KGCN beberapa parameter yang disesuaikan diantaranya:

Tabel 1 Hyperparameter Tuning

<i>Embedding Dimension</i>	Ukuran dimensi embedding dalam merepresentasikan isi node
<i>Iteration number</i>	Jumlah perulangan yang dilakukan model
<i>Learning_Rate</i>	Langkah yang diambil untuk memperbarui bobot model selama pelatihan.

Metode hyperparameter yang akan digunakan adalah *GridSearchCV* dimana parameter akan ditentukan secara manual berdasarkan metrik yang sudah dipilih[16][17].

2.9 Metrik Evaluasi

Metrik evaluasi adalah alat untuk mengukur kinerja model pada berbagai tugas seperti klasifikasi biner, multi-kelas, regresi, segmentasi gambar[18]. Berikut metrik evaluasi yang digunakan pada sistem rekomendasi:

2.9.1 Recall@K

Merupakan sebuah evaluasi untuk rekomendasi yang diberikan model. Recall@K merepresentasikan berapa banyak item di top_K yang termasuk kedalam *ground_truth_item* [11].

2.9.2 Precision@K

Menunjukkan jumlah item K di *ground_truth_item* yang termasuk kedalam top_K dan relevan untuk direkomendasikan kepada pengguna [19].

2.9.3 Normalized Discounted Cumulative Gain (NDGC@K)

Digunakan untuk merepresentasikan kualitas peringkat rekomendasi yang dihasilkan, semakin mendekati nilai 1 mengindikasikan kualitas peringkat rekomendasi yang sangat baik [10]

2.9.4 AUC (Area Under Curve)

Metric yang digunakan untuk mengevaluasi kemampuan model dalam melakukan klasifikasi, nilai yang lebih tinggi menunjukkan kinerja model yang lebih baik [22].

2.10 Output

Diberikan pasangan user dan film (u_i, i_j) dari hasil prediksi persamaan (3) yang menghasilkan skor probabilitas interaksi yang dilakukan oleh user dengan item[19].


2.11 Penelitian Terdahulu

Penelitian terdahulu [3] berfokus pada pengembangan metode sistem rekomendasi melalui pendekatan yang disebut *Knowledge Graph Convolutional Networks* (KGCN). Pada penelitian ini mengalami permasalahan seperti dimensionalitas tinggi dan heterogenitas KG yang membuatnya sulit untuk diolah secara langsung dalam model pembelajaran mesin, untuk mengatasi masalah tersebut digunakan metode agregasi penjumlahan informasi dari tetangga dengan cara menjumlahkan informasi dari 2 entitas yang terhubung dan menggabungkannya dengan bias yang relevan sehingga menangkap baik informasi struktural maupun semantik KG. Metode ini menghasilkan AUC 0.978 pada dataset MovieLens. Pada penelitian [19], pengaruh knowledge graph memberikan hasil AUC 0.982 dijelaskan melalui penerapan metode CUIKG (Combining User-end and Item-end Knowledge Graph learning). Metode ini secara bersamaan mempelajari embedding pengguna dan item dari knowledge graph di kedua sisi, yang memungkinkan model untuk menangkap relevansi antara pengguna dan item dengan lebih baik. Dengan memanfaatkan informasi semantik yang kaya dari knowledge graph, model ini dapat mengatasi masalah sparsity data dengan

memperkenalkan lebih banyak hubungan semantik yang mendukung akurasi rekomendasi. Selain itu, model ini memperhitungkan atribut pengguna dan bagaimana atribut tersebut mempengaruhi preferensi mereka terhadap item, sehingga menciptakan representasi yang lebih akurat.

BAB III METODOLOGI PENELITIAN

3.1 Metode Penelitian



Gambar 1 Metode Penelitian

3.2 Pendekatan Penelitian

Penelitian dilakukan dengan pendekatan kuantitatif, yaitu pendekatan dalam menguji teknik *importance sampling* berbasis bobot edge pada model *Graph Convolutional Network* (GCN).

Importance sampling dilakukan dengan memilih edge yang memiliki bobot (edge_weight) lebih besar dari threshold tertentu, kemudian sampling edge dilakukan secara probabilistik proporsional terhadap bobot tersebut. Teknik ini

bertujuan untuk memfokuskan pelatihan pada hubungan yang lebih penting antara pengguna dan item, sehingga meningkatkan efisiensi dan akurasi model.

Evaluasi model dilakukan menggunakan metrik evaluasi seperti Precision@K, Recall@K, NDCG@K, dan AUC untuk mengukur kualitas rekomendasi dan mengurangi waktu komputasi selama training.

3.3 Dataset

Pada penelitian ini, terdapat 3 file dataset diperoleh dari website grouplens yang berisi rating film yang telah diberikan oleh user. Dataset ini terdiri dari 6040 users, 3883 film dan 1000209 data rating.

Tabel 2 Atribut User

No	Atribut	Deskripsi
1	UserID	ID yang mewakili user
2	Gender	Merupakan atribut user yang menjelaskan jenis kelamin user
3	Age	Merupakan atribut user yang berisikan kategori umur user
4	Occupation	Merupakan atribut user yang berisikan kategori pekerjaan user

Tabel 3 Atribut Film

No	Atribut	Deskripsi
1	MovieID	ID yang mewakili film tertentu
2	Title	Merupakan Atribut judul film

3	Genres	Merupakan atribut film yang mengkategorikan genre film
---	--------	--

Tabel 4 Rating Film

No	Atribut	Deskripsi
1	UserID	ID yang mewakili user tertentu
2	MovieID	ID yang mewakili film tertentu
3	Ratings	Penilaian yang diberikan user terhadap film (1-5 bintang)

3.4 Preprocessing Data

Preprocessing data merupakan tahap untuk membersihkan data agar data tidak mengurangi akurasi model sehingga data mentah bisa dipakai saat dianalisis, dilakukan beberapa tahap preprocessing:


3.4.1 Penggabungan Dataset

Dataset akan digabung menjadi satu berdasarkan kesamaan MovieID, dan userID agar didapatkan informasi yang lebih jelas mengenai bagaimana user berinteraksi dengan film tersebut serta nilai dari atribut yang dimiliki user dan juga film.

3.4.2 Label Encoding

Label encoding untuk mengubah setiap data kategorik menjadi data numerik unik yang memiliki makna tanpa memperhatikan urutan atau tingkatan [23][24], misalnya pada kolom gender terdapat 2 kategori yaitu, M dan F, melalui label encoding, kategori tersebut akan di-*transform* menjadi 0 dan 1.

3.5 Knowledge Graph



Gambar 2 Arsitektur Knowledge Graph

Setelah data berhasil melalui tahap preprocessing, langkah selanjutnya adalah membangun Knowledge Graph (KG) digunakan untuk merepresentasikan hubungan kompleks antara user dan item, serta atribut-atribut tambahan dari masing-masing entitas.

3.6 Representasi Node

Langkah awal dalam membangun KG adalah membuat representasi node untuk setiap entitas yang terlibat. Entitas ini berasal dari atribut-atribut user maupun film, antara lain:

- UserID
- MovieID
- Genre
- Age
- Occupation
- Gender

Setiap entitas akan di-*mapping* ke dalam ID numerik unik untuk menghindari duplikasi dan memastikan konsistensi saat membangun graph. Representasi node ini bertujuan untuk menciptakan struktur graph heterogen di mana setiap jenis entitas dapat dikenali secara eksplisit.

3.7 Data Interaksi User-Item

Interaksi eksplisit antara user dan film direpresentasikan dalam bentuk matrix interaksi seperti persamaan (1) interaksi user-item didefinisikan sebagai:

$$Y \in \mathbb{R}^{M \times N} \quad (1)$$

Penjelasan:

Y = Interaksi antara pengguna dan item

$\mathbb{R}$ = Himpunan bilangan real dalam matrix Y

M = Jumlah baris yang mewakili jumlah pengguna dalam matrix

N = Jumlah kolom item yang mewakili jumlah item dalam matrix

dimana nilai Y mereprestasikan rating yang diberikan user ke- i terhadap film ke- j . Nilai rating tersebut akan digunakan untuk bobot relasi antar node user dan film.

3.8 Pembentukan Triplet

Hubungan antar entitas dalam Knowledge Graph disusun dalam bentuk triplet menggunakan persamaan (2), secara sistematis triplet dinyatakan sebagai berikut [12]:

$$\mathcal{G} = \{(h, r, t) \mid h \in \mathcal{E}, t \in \mathcal{E}, r \in \mathcal{R}\} \quad (2)$$

Penjelasan:

$\mathcal{G}$ = Sekumpulan triple yang menyimpan informasi hubungan antar entitas

(h, r, t) = kepala, relasi dan ekor dari sebuah triple pengetahuan

$\mathcal{E}$ = Himpunan entitas dalam knowledge graph

$\mathcal{R}$ = Himpunan relasi dalam knowledge graph

Triplet-triplet ini mencerminkan hubungan semantik dan struktural yang akan digunakan sebagai dasar dalam pembuatan edge pada graph.

3.9 Graph Convolutional Network

GCN digunakan untuk melakukan propagasi informasi antar node dan menghasilkan representasi (embedding) yang merepresentasikan relasi kompleks antara user, item, dan atribut (seperti genre). Tahapan dalam GCN meliputi:

3.9.1 Embedding Awal

Pada tahap awal proses pelatihan, setiap node dalam graph, seperti pengguna, *gender*, *age*, *occupation*, film, genre, diberikan vektor embedding secara acak. Pemberian embedding awal secara acak ini bertujuan sebagai titik awal bagi model untuk mempelajari informasi yang bermakna.

3.9.2 Importance Sampling

Kemudian dilakukan sampling menggunakan *importance sampling* untuk setiap node user dengan memilih tetangga paling relevan berdasarkan bobot relasinya melalui persamaan (3):

$$\hat{\mu}_q = \frac{1}{n} \sum_j \frac{p(\hat{v}_j)}{q(\hat{v}_j)} f(\hat{v}_j) \quad (3)$$

Penjelasan:

n = Jumlah tetangga yang diambil sampelnya

$p(\hat{v}_j)$ = bobot dari *node* atau *edge* $\hat{v}_j$

$f(\hat{v}_j)$ = informasi node $\hat{v}_j$ yang akan dipropagasi

$\hat{v}_j$ = node tetangga yang diambil dari distribusi q

Sampling dilakukan pada *2-layer* dimana masing-masing *layer* diambil 5 nodes tetangga berdasarkan skor hubungan yang dihitung menggunakan *dot product* antar embedding dan bobot menggunakan persamaan (4):

$$\pi_r^u = g(u, r) \quad (4)$$

Penjelasan:

π_r^u = Menggambarkan pentingnya hubungan r dengan pengguna u

$g(u, r)$ = Fungsi interaksi antara embedding pengguna dan embedding relasi

Setelah didapat bobot hubungan, selanjutnya dilakukan normalisasi pada bobot hubungan menggunakan persamaan (5):

$$\tilde{\pi}_{r,v,e}^u = \frac{\exp(\pi_{r,v,e}^u)}{\sum_{e \in N(v)} \exp(\pi_{r,v,e}^u)} \quad (5)$$

3.9.3 Message Passing & Sum Aggregation

Embedding dari node tetangga yang telah disampling dipropagasikan ke node pusat dengan bobot hasil normalisasi, sehingga akan menghasilkan embedding baru untuk node user yang dihasilkan dari penjumlahan informasi yang terhubung ke user langsung, melalui persamaan (6).

$$agg_{sum} = \sigma(W \cdot (v + v_{S(v)}^u) + b) \quad (6)$$

Penjelasan:

W = Transformasi bobot

v = Embedding node pusat

b = Transformasi bias

σ = Nonlinear function

Proses ini dikenal sebagai message passing dengan agregasi sum (penjumlahan), di mana setiap node mengumpulkan informasi dari tetangganya dengan menjumlahkan embedding tetangga yang sudah ditimbang.

3.9.4 Prediksi

Kemudian dilakukan skor prediksi model memanfaatkan interaksi pengguna-item yang direpresentasikan dalam bentuk matriks Y serta

struktur KG $\mathcal{G}$. Prediksi probabilitas interaksi yang dilakukan oleh pengguna u dengan item v dihitung pada persamaan (7) [25]:

$$\hat{y}_{uv} = \mathcal{F}(u, v | \theta, Y, \mathcal{G}) \quad (7)$$

Penjelasan:

$\hat{y}_{uv}$ = Nilai prediksi probabilitas pengguna u akan berinteraksi dengan item v

$\mathcal{F}$ = Fungsi untuk memprediksi nilai $\hat{y}_{uv}$

θ = Parameter model mengoptimalkan fungsi prediksi

Y = Matriks interaksi pengguna-item

$\mathcal{G}$ = *Knowledge Graph* memeberikan konteks tambahan tentang hubungan antar entitas

3.10 Metrik Evaluasi

Dari item diambil, akan dilakukan evaluasi menggunakan metrik:

3.10.1 Recall@K

$$Rec@K = \frac{ground_truth_items \cap top_k}{ground_truth_items} \quad (8)$$

3.10.2 Precision@K

$$Pre@K = \frac{ground_truth_items \cap top_k}{top_k} \quad (9)$$

3.10.3 NDCG@K

$$NDCG(u) = \frac{DCG@K}{IDCG@K} \quad (10)$$

Dimana didapat dari menghitung *Discounted Cumulative Gain* (DCG) dalam memperhitungkan posisi item, jika nilai DCG tinggi menunjukkan lebih banyak item dengan peringkat tinggi [20] dan *Ideal Discounted Cumulative Gain* (IDCG) yang dijadikan sebagai perbandingan[21].

$$DCG(u) = \sum_{j=1}^n \frac{2^{rel_i} - 1}{\log_2(i + 1)} \quad (11)$$

$$IDCG(u) = \sum_{i=1}^{|rel_k|} \frac{2^{rel_i-1}}{\log_2(i + 1)} \quad (12)$$

Penjelasan:

K = Peringkat maksimum

i = posisi item dalam peringkat

rel_i = nilai relevansi item pada posisi i

3.10.4 AUC

$$AUC = \frac{1}{|R||N|} \sum_{i \in R} \sum_{j \in N} \delta(s_i < s_j) \quad (13)$$

Penjelasan:

R = Himpunan item relevan rating ≥ 4

N = Himpunan item tidak relevan

s_i = Skor prediksi model untuk item i

s_j = Skor prediksi model untuk item j

BAB IV HASIL DAN PEMBAHASAN

4.1 Hasil

4.1.1 Dataset

MovieID	Title	Genres
0	1	Toy Story (1995) Animation Children's Comedy
1	2	Jumanji (1995) Adventure Children's Fantasy
2	3	Grumpier Old Men (1995) Comedy Romance
3	4	Waiting to Exhale (1995) Comedy Drama
4	5	Father of the Bride Part II (1995) Comedy
...	...	...
3878	3948	Meet the Parents (2000) Comedy
3879	3949	Requiem for a Dream (2000) Drama
3880	3950	Tigerland (2000) Drama
3881	3951	Two Family House (2000) Drama
3882	3952	Contender, The (2000) Drama Thriller

3883 rows x 3 columns

Gambar 3 Data Movies

Pada dataset movies terdapat 3883 data film dengan 3 atribut yaitu, MovieID, Title, Genres.

UserID	MovieID	Rating
0	1	1193 5
1	1	661 3
2	1	914 3
3	1	3408 4
4	1	2355 5
...	...	...
1000204	6040	1091 1
1000205	6040	1094 5
1000206	6040	562 5
1000207	6040	1096 4
1000208	6040	1097 4

1000209 rows x 3 columns

Gambar 4 Data Rating

Pada dataset rating terdapat 1000209 data dengan 3 atribut yaitu, UserID, MovieID, Rating, dataset ini menjelaskan tentang rating yang telah user berikan terhadap film yang telah ditonton dengan skala rating 1-5.

	UserID	Gender	Age	Occupation
0	1	F	1	10
1	2	M	56	16
2	3	M	25	15
3	4	M	45	7
4	5	M	25	20
...	...	...	...	...
6035	6036	F	25	15
6036	6037	F	45	1
6037	6038	F	56	1
6038	6039	F	45	0
6039	6040	M	25	6

6040 rows x 4 columns

Gambar 5 Data Users

Pada dataset users terdapat 6040 data dengan 4 atribut yaitu, UserID, Gender, Age, Occupation. Dimana untuk atribut Age berisikan kelompok umur yang sudah dibentuk, sedangkan atribut occupation berisikan jenis pekerjaan yang sudah diwakili dalam bentuk numerik.

4.1.2 Penggabungan Dataset

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1000209 entries, 0 to 1000208
Data columns (total 8 columns):
#   Column      Non-Null Count  Dtype
---  ---
0   UserID      1000209 non-null  int64
1   Gender      1000209 non-null  object
2   Age         1000209 non-null  int64
3   Occupation  1000209 non-null  int64
4   MovieID     1000209 non-null  int64
5   Rating      1000209 non-null  int64
6   Title       1000209 non-null  object
7   Genres      1000209 non-null  object
```

Gambar 6 Penggabungan Dataset

Kemudian dilakukan penggabungan dataset berdasarkan kesamaan UserID, dan MovieID, sehingga total dataset setelah digabung menjadi 1000209 data dengan 8 atribut.

4.1.3 Label Encoding

	UserID	Gender	Age	Occupation	MovieID	Rating	Title		Genres
0	1	0	1		10	1193	5	One Flew Over the Cuckoo's Nest (1975)	Drama
1	1	0	1		10	661	3	James and the Giant Peach (1996)	Animation Children's Musical
2	1	0	1		10	914	3	My Fair Lady (1964)	Musical Romance
3	1	0	1		10	3408	4	Erin Brockovich (2000)	Drama
4	1	0	1		10	2355	5	Bug's Life, A (1998)	Animation Children's Comedy
...	...	...	...		...	...	...	...	...
1000204	6040	1	25	6	1091	1	Weekend at Bernie's (1989)		Comedy
1000205	6040	1	25	6	1094	5	Crying Game, The (1992)	Drama Romance War	
1000206	6040	1	25	6	562	5	Welcome to the Dollhouse (1995)	Comedy Drama	
1000207	6040	1	25	6	1096	4	Sophie's Choice (1982)		Drama
1000208	6040	1	25	6	1097	4	E.T. the Extra-Terrestrial (1982)	Children's Drama Fantasy Sci-Fi	
1000209 rows x 8 columns									

Gambar 7 Label Encoding

Kemudian dilakukan label encoding pada kolom gender, dengan merubah atribut kategorik menjadi bentuk numerik. Pada atribut gender female = 0 dan male = 1, perubahan ini dilakukan berdasarkan urutan abjad, dimana huruf 'F' pada kata Female muncul lebih awal dalam alfabet dibandingkan huruf 'M' pada kata Male.

4.1.4 Knowledge Graph

4.1.4.1 Representasi Node

Setelah penerapan label encoding, langkah pertama adalah membentuk representasi node dari semua entitas dalam dataset. Entitas tersebut dikelompokkan menjadi:

- Node User: merepresentasikan ID pengguna
- Node Movie: merepresentasikan ID film
- Node Genre: merepresentasikan genre seperti Action, Drama, Comedy
- Node Gender: merepresentasikan laki-laki atau Perempuan
- Node Age: merepresentasikan kelompok umur
- Node Occupation: merepresentasikan pekerjaan

Setiap entitas di-*mapping* ke ID numerik unik untuk mencegah terjadinya duplikasi data, dan membentuk struktur awal graph heterogen.

4.1.4.2 Data Interaksi User-Item

Dari data rating, dibentuk matriks interaksi $Y \in \mathbb{R}^{M \times N}$, sehingga didapatkan $Y \in \mathbb{R}^{6040 \times 3883}$. Elemen Y berisi nilai rating 1-5 yang akan digunakan untuk memberikan bobot pada edge antara node pengguna dan node film pada graph.

4.1.4.3 Triplet Hubungan Entitas Relasi Entitas

Selanjutnya, dibentuk relasi antar node dalam triplet (h, r, t), sehingga menghasilkan hubungan antara entitas:

Tabel 5 Triplet Hubungan

Head (h)	Relation (r)	Tail (t)
UserID	memberi rating	MovieID
UserID	memiliki umur	5
UserID	bekerja sebagai	writer
MovieID	memiliki genre	Fantasy
MovieID	memiliki judul	Jumanji

Triplet hubungan ini digunakan sebagai *Knowledge Graph* untuk menyimpan relasi antar entitas yang merepresentasikan informasi tambahan selain user-item.

4.1.5 Splitting Dataset

Dataset dibagi menjadi tiga bagian, yaitu *train*, *validation* dan *test* dengan proporsi 80:10:10. Pada data *train* digunakan untuk melatih model, data *validation* digunakan untuk melatih model melalui hyperparameter yang sudah ditetapkan, dan data *test* digunakan untuk mengevaluasi model.

4.1.6 Graph Convolutional Network

4.1.6.1 Embedding Awal

Pada tahap awal pelatihan, setiap node dalam knowledge graph akan direpresentasikan dalam bentuk vektor embedding berdimensi 64. Embedding ini pada awalnya diinisialisasi secara acak dan akan diperbarui selama pelatihan.

Contoh:

Embedding awal berdimensi 4, maka

Node	Embedding
U1	[0.1, 0.2, 0.0, 0.4]
M1	[0.4, 0.1, 0.1, 0.3]
M2	[0.2, 0.3, 0.2, 0.1]
Action	[0.1, 0.0, 0.2, 0.2]
Thriller	[0.3, 0.2, 0.0, 0.2]

Comedy	[0.3, 0.1, 0.2, 0.1]
Romance	[0.4, 0.1, 0.2, 0.0]
M	[0.0, 0.2, 0.1, 0.2]
25	[0.2, 0.2, 0.2, 0.2]
Engineer	[0.1, 0.1, 0.3, 0.3]

Embedding awal akan diperbarui melalui proses propagasi informasi antar node graph.

4.1.6.2 Importance Sampling

Karena graph besar memiliki banyak tetangga, maka teknik importance sampling digunakan untuk memilih tetangga yang paling relevan. Langkah:

1. Setiap node pusat dihitung skor relevansi terhadap tetangga menggunakan dot produk
2. Hasil skor diubah menjadi probabilitas (softmax)
3. Diambil top-5 tetangga untuk setiap relasi

Contoh:

1. Hitung skor relevansi

$$\begin{aligned}
 \text{score}_{U1, M1} &= e(U1) * e(M1) \\
 &= (0.1)(0.4) + (0.2)(0.1) + (0.0)(0.1) + (0.4)(0.3) \\
 &= 0.04 + 0 + 0.12 = 0.18 \times 5 = 0.90
 \end{aligned}$$

$$\begin{aligned}
 \text{score}_{U1, M2} &= e(U1) * e(M2) \\
 &= (0.1)(0.2) + (0.2)(0.3) + (0.0)(0.2) + (0.4)(0.1) \\
 &= 0.02 + 0.6 + 0 = 0.12 \times 3 = 0.36
 \end{aligned}$$

2. Hitung probabilitas (Softmax)

$$\text{softmax}(0.18, 0.12) = \left(\frac{e^{0.90}}{e^{0.90} + e^{0.36}}, \frac{e^{0.36}}{e^{0.90} + e^{0.36}} \right)$$

$$e^{0.90} \approx 2.46$$

$$e^{0.36} \approx 1.43$$

$$\text{Total} = 3.89$$

Sehingga didapatkan skor probabilitas

$$\text{softmax}(U1, M1) = \frac{2.46}{2.46 + 1.43} \approx 0.63$$

$$\text{softmax}(U1, M2) = \frac{1.43}{2.46 + 1.43} = 0.37$$

Maka bobot relasi U1, M1 dan U1, M2 akan dipilih untuk dilakukan message passing.

4.1.6.3 Message Passing & Sum Aggregation

Setelah importance dihitung, dilakukan agregasi informasi dari tetangga:

$$v_{agg} = (v_{M1} * 0.63 + v_{M2} * 0.37)$$

$$v_{agg} = ([0.4, 0.1, 0.1, 0.3] * 0.63) + (0.2, 0.3, 0.2, 0.1 * 0.37)$$

$$v_{agg} = ([0.252, 0.063, 0.063, 0.189] + (0.074, 0.111, 0.074, 0.037))$$

$$v_{agg} = [0.326, 0.174, 0.137, 0.226]$$

Sehingga didapatkan embedding baru untuk user 1 adalah [0.326, 0.174, 0.137, 0.226].

4.1.6.4 Prediksi Interaksi User-Item

Setelah embedding node pusat sudah diperbarui, maka dilakukan perhitungan prediksi interaksi antara U1 dan M1 sehingga:

$$\begin{aligned} & \text{score}(U1, M1) \\ &= (0.326 * 0.4) + (0.174 * 0.1) + (0.137 * 0.1) + (0.226 * 0.3) \\ &= 0.1304 + 0.0174 + 0.0137 + 0.0678 \\ &= 0.2293 \end{aligned}$$

Sehingga dihasilkan nilai skor prediksi 0.2293 U1 akan berinteraksi dengan M1

4.1.7 Pelatihan Model

Model awal dilatih terlebih dahulu menggunakan *data training* menggunakan parameter pada tabel 6.

Tabel 6 Parameter Model Awal

Parameter	Nilai
Optimizer	Adam
Batch Size	128
Learning Rate	0.005
Weight Decay	0.0001
Embedding Size	64

Model Layers	2
--------------	---

Model dilatih selama 10 epoch dengan menghasilkan sebanyak $k = 10$ item rekomendasi pada setiap iterasi pelatihan. Hasil penelitian menunjukkan bahwa penerapan teknik importance sampling mampu meningkatkan performa model secara signifikan dibandingkan dengan uniform sampling, khususnya pada metrik evaluasi Precision@K, Recall@K, NDCG@K, dan AUC. Hasil lebih lengkap terdapat pada tabel 7 dibawah ini.


Tabel 7 Perbandingan Waktu Komputasi Training

Epoch	Importance Sampling		Uniform Sampling	
	Waktu (s)	AUC	Waktu (s)	AUC
1	219.55s	0.6843	199.98s	0.6465
2	223.82s	0.8393	197.19s	0.7766
3	441.95s	0.8485	478.49s	0.7866
4	536.63s	0.8521	513.62s	0.7926
5	617.53s	0.8554	592.25s	0.7953
6	663.63s	0.8586	626.83s	0.7969
7	699.07s	0.8616	664.86s	0.7986
8	735.14s	0.8620	690.11s	0.7988
9	761.97s	0.8628	694.50s	0.7994
10	768.45s	0.8636	722.15s	0.8004

Penerapan importance sampling terbukti memberikan nilai AUC yang lebih tinggi dibandingkan uniform sampling, yang menunjukkan kemampuan model dalam membedakan item relevan dan tidak relevan secara lebih efektif. Meskipun demikian, teknik ini memerlukan waktu komputasi yang lebih lama pada setiap epoch, menandakan adanya trade-off antara akurasi dan efisiensi waktu dalam proses pelatihan. Hal ini disebabkan oleh adanya proses tambahan untuk menghitung distribusi bobot penting dari edges sebelum dilakukan proses sampling. Meskipun memerlukan waktu komputasi yang lebih tinggi, peningkatan performa

evaluasi yang signifikan menjadikan keuntungan, karena akurasi dan relevansi hasil rekomendasi yang dihasilkan oleh model menjadi lebih optimal.

Berikut perbandingan metrik Precision@K, Recall@K, NDCG@K selama 10 epoch pada gambar 9.



Gambar 8 Metrik Evaluasi

Hasil menunjukkan perbandingan kinerja model dengan menerapkan *importance sampling* dan *uniform sampling* selama pelatihan. Pada metrik Precision@10, model yang menerapkan *importance sampling* secara konsisten memperoleh nilai 0.50 lebih tinggi dibandingkan model yang menerapkan *uniform sampling* yang hanya mencapai 0.28, dari metrik ini menunjukkan bahwa penerapan *importance sampling* dapat membantu model merekomendasikan film yang benar-benar relevan untuk user pada posisi 10 teratas. Pada metrik Recall@10, model yang menerapkan *importance sampling* memiliki performa yang cukup stabil sebesar 1.000 walaupun sempat drop ke 0.9963, sedangkan pada model yang menerapkan *uniform sampling* mendapatkan nilai yang sedikit lebih rendah sebesar 0.9963. Hal ini menunjukkan bahwa *importance sampling* membantu model dalam menemukan hampir seluruh film relevan dalam top rekomendasi.

Pada metrik NDCG@10 menunjukkan perbedaan yang cukup signifikan, model yang menerapkan *importance sampling* mampu mendapatkan skor 0.96, sedangkan model yang menerapkan *uniform sampling* hanya mendapatkan skor 0.88. Ini menunjukkan bahwa model yang menerapkan *importance sampling* dapat

menempatkan posisi item yang sangat relevan di posisi tertinggi dalam daftar rekomendasi.

4.1.8 Hyperparameter

Kemudian dilakukan percobaan hyperparameter dengan memanfaatkan data validasi dengan beberapa parameter pada tabel 8.

Tabel 8 Hyperparameter Model

Parameter	Nilai
Learning_Rate	0.001, 0.01, 0.05
Embedding Size	32
Epoch	20

Berdasarkan hasil percobaan hyperparameter dengan optimizer Adam, kombinasi parameter terbaik diperoleh pada learning rate sebesar 0.001. Pada data validasi, konfigurasi ini menghasilkan precision@10 sebesar 0.2904, recall@10 sebesar 1.0000, NDCG@10 sebesar 0.8513, dan AUC sebesar 0.7459. Sementara itu, pada learning rate 0.01 hanya diperoleh AUC sebesar 0.7167, dan pada learning rate 0.05 AUC yang didapatkan turun signifikan menjadi 0.5002. Dengan demikian, learning rate 0.001 dipilih sebagai konfigurasi terbaik karena memberikan performa evaluasi tertinggi pada data validasi, hasil tersebut akan dijadikan acuan untuk melanjutkan ke tahap pelatihan ulang model sepenuhnya pada data latih, agar model yang dihasilkan bisa belajar secara maksimal dari seluruh data yang tersedia.

4.1.9 Pelatihan Ulang

Dilakukan pelatihan kembali menggunakan parameter terbaik dari hasil *GridSearchCV*, dimana model mendapatkan peningkatan NDCG@K dan AUC sebesar 1% selama 10 epoch, seperti pada gambar 9.

```

=====Training Session=====
P@10: 0.5005 | R@10: 1.0000 | NDCG@10: 0.8745 | AUC: 0.5479 | Time: 100.07s | Total time: 100.07s
P@10: 0.4994 | R@10: 1.0000 | NDCG@10: 0.9495 | AUC: 0.7712 | Time: 105.07s | Total time: 205.14s
P@10: 0.4994 | R@10: 1.0000 | NDCG@10: 0.9660 | AUC: 0.8451 | Time: 102.64s | Total time: 307.78s
P@10: 0.4977 | R@10: 0.9961 | NDCG@10: 0.9641 | AUC: 0.8591 | Time: 100.77s | Total time: 408.54s
P@10: 0.5001 | R@10: 1.0000 | NDCG@10: 0.9687 | AUC: 0.8642 | Time: 107.37s | Total time: 515.91s
P@10: 0.4992 | R@10: 1.0000 | NDCG@10: 0.9684 | AUC: 0.8669 | Time: 109.17s | Total time: 625.08s
P@10: 0.4987 | R@10: 1.0000 | NDCG@10: 0.9696 | AUC: 0.8696 | Time: 114.39s | Total time: 739.47s
P@10: 0.5037 | R@10: 1.0000 | NDCG@10: 0.9712 | AUC: 0.8711 | Time: 107.05s | Total time: 846.52s
P@10: 0.5003 | R@10: 0.9961 | NDCG@10: 0.9676 | AUC: 0.8730 | Time: 107.38s | Total time: 953.89s
P@10: 0.4990 | R@10: 1.0000 | NDCG@10: 0.9715 | AUC: 0.8758 | Time: 103.90s | Total time: 1057.79s

```

Gambar 9 Pelatihan ulang

Peningkatan ini mengindikasikan bahwa pemilihan hyperparameter yang lebih optimal berkontribusi pada peningkatan kualitas rekomendasi, khususnya dalam hal relevansi urutan item dan kemampuan membedakan item relevan dan tidak relevan. Selain itu, waktu pelatihan per epoch juga mengalami penurunan signifikan, dari rata-rata sekitar 566 detik menjadi sekitar 106 detik, sehingga pelatihan menjadi lebih efisien tanpa mengorbankan akurasi model.

4.1.10 Test Model

Model sistem rekomendasi yang telah dilatih dan disempurnakan melalui pelatihan ulang menunjukkan performa yang sangat baik pada tahap evaluasi menggunakan data testing. Berdasarkan hasil evaluasi diperoleh nilai $\text{Precision@10} = 0.4988$, yang berarti hampir 50% dari item yang direkomendasikan berada dalam kategori relevan untuk user. Recall@10 mencapai angka maksimum sebesar 1.0000, yang berarti seluruh item relevan berhasil direkomendasikan oleh sistem dalam daftar 10 film teratas. Metrik NDCG@10 mendapatkan 0.9719 mencerminkan bahwa model dapat mengurutkan film yang relevan secara optimal, sedangkan AUC mendapatkan 0.8798 menunjukkan kemampuan model dalam membedakan antara item relevan dan tidak relevan.

BAB V KESIMPULAN DAN SARAN

5.1 Saran

Berdasarkan hasil penelitian dan analisis yang telah dilakukan, dapat disimpulkan bahwa penerapan *Knowledge Graph Convolutional Network* (KGCN) dengan teknik *importance sampling* dalam sistem rekomendasi film memberikan hasil yang signifikan dalam meningkatkan performa model. Pemanfaatan KG memungkinkan integrasi informasi kontekstual seperti genre film, usia, jenis kelamin, dan pekerjaan pengguna ke dalam model rekomendasi, yang memperkaya pemahaman terhadap preferensi pengguna. Teknik *importance sampling* terbukti efektif dalam memilih tetangga paling relevan selama proses pelatihan, menghasilkan skor evaluasi yang lebih baik dibandingkan *uniform sampling*. Hal ini terlihat dari peningkatan skor AUC, Precision@10, Recall@10, dan NDCG@10 selama pelatihan. Evaluasi pada data testing menunjukkan hasil yang konsisten mengindikasikan bahwa model memiliki generalisasi yang baik dan tidak mengalami *overfitting*. Penerapan hyperparameter tuning juga memberikan dampak signifikan terhadap kinerja model, dengan kombinasi terbaik adalah learning rate 0.001, embedding size 32, dan jumlah epoch 20. Secara keseluruhan, penelitian ini menunjukkan bahwa integrasi *knowledge graph* dan *importance sampling neighbor selection* dapat menjadi pendekatan yang efisien dan akurat dalam membangun sistem rekomendasi berbasis GCN. Proses tuning hyperparameter memberikan pengaruh besar terhadap performa model, dengan konfigurasi terbaik yang ditemukan adalah learning rate 0.001, embedding size 32, dan 20 epoch. Secara keseluruhan, penelitian ini membuktikan bahwa menggabungkan pendekatan *knowledge graph* dengan pemilihan tetangga berbasis *importance* merupakan metode yang efektif dan tepat dalam mengembangkan sistem rekomendasi berbasis *Graph Convolutional Networks* (GCN).

5.2 Saran

Saran untuk pengembangan lebih lanjut dari penelitian ini

1. Penelitian dapat diperluas dengan menambahkan atribut tambahan seperti waktu, Lokasi atau perangkat yang digunakan agar model rekomendasi menjadi lebih kontekstual dan personal
2. Penggunaan *Relational Graph Convolutional Network* (R-GCN) atau *Graph Attention Network* (GAT) dapat menjadi alternatif yang menarik untuk menangkap relasi multi-tipe antar node dengan lebih akurat.

DAFTAR PUSTAKA

- [1] Q. Guo *et al.*, “A Survey on Knowledge Graph-Based Recommender Systems,” *IEEE Trans Knowl Data Eng*, vol. 34, no. 8, pp. 3549–3568, Aug. 2022, doi: 10.1109/TKDE.2020.3028705.
- [2] Y. Ji *et al.*, “Accelerating Large-Scale Heterogeneous Interaction Graph Embedding Learning via Importance Sampling,” *ACM Trans Knowl Discov Data*, vol. 15, no. 1, Jan. 2021, doi: 10.1145/3418684.
- [3] H. Wang, M. Zhao, X. Xie, W. Li, and M. Guo, “Knowledge graph convolutional networks for recommender systems,” in *The Web Conference 2019 - Proceedings of the World Wide Web Conference, WWW 2019*, Association for Computing Machinery, Inc, May 2019, pp. 3307–3313. doi: 10.1145/3308558.3313417.
- [4] Y. Afoudi, M. Lazaar, and M. Al Achhab, “Hybrid recommendation system combined content-based filtering and collaborative prediction using artificial neural network,” *Simul Model Pract Theory*, vol. 113, Dec. 2021, doi: 10.1016/j.simpat.2021.102375.
- [5] A. Hicham, P. A. Sabri, and P. H. Tairi, “A Survey on Educational Data Mining [2014-2019] 1 st,” 2020.
- [6] W. T. Wu *et al.*, “Data mining in clinical big data: the frequently used databases, steps, and methodological models,” Dec. 01, 2021, *BioMed Central Ltd*. doi: 10.1186/s40779-021-00338-z.
- [7] A. Bartschat, M. Reischl, and R. Mikut, “Data mining tools,” *Wiley Interdiscip Rev Data Min Knowl Discov*, vol. 9, no. 4, Jul. 2019, doi: 10.1002/widm.1309.
- [8] Z. Batmaz, A. Yurekli, A. Bilge, and C. Kaleli, “A review on deep learning for recommender systems: challenges and remedies,” *Artif Intell Rev*, vol. 52, no. 1, pp. 1–37, Jun. 2019, doi: 10.1007/s10462-018-9654-y.
- [9] H. Ko, S. Lee, Y. Park, and A. Choi, “A Survey of Recommendation Systems: Recommendation Models, Techniques, and Application Fields,” Jan. 01, 2022, *MDPI*. doi: 10.3390/electronics11010141.

- [10] L. Wang and Y. Zhang, “Digital Dissemination of Information Based on Knowledge Graph Recommendation Algorithm,” *Informatica (Slovenia)*, vol. 48, no. 19, pp. 31–44, 2024, doi: 10.31449/inf.v48i19.6561.
- [11] J. A. P. Sacenti, R. Fileto, and R. Willrich, “Knowledge graph summarization impacts on movie recommendations,” *J Intell Inf Syst*, vol. 58, no. 1, pp. 43–66, Feb. 2022, doi: 10.1007/s10844-021-00650-z.
- [12] X. Wang *et al.*, “Learning intents behind interactions with knowledge graph for recommendation,” in *The Web Conference 2021 - Proceedings of the World Wide Web Conference, WWW 2021*, Association for Computing Machinery, Inc, Apr. 2021, pp. 878–887. doi: 10.1145/3442381.3450133.
- [13] H. Xia, K. Huang, and Y. Liu, “Unexpected interest recommender system with graph neural network,” *Complex and Intelligent Systems*, vol. 9, no. 4, pp. 3819–3833, Aug. 2023, doi: 10.1007/s40747-022-00849-9.
- [14] Y. Wang, X. F. Ma, and M. Zhu, “A knowledge graph algorithm enabled deep recommendation system,” *PeerJ Comput Sci*, vol. 10, 2024, doi: 10.7717/PEERJ-CS.2010.
- [15] U. A. Bhatti, H. Tang, G. Wu, S. Marjan, and A. Hussain, “Deep Learning with Graph Convolutional Networks: An Overview and Latest Applications in Computational Intelligence,” 2023, *Wiley-Hindawi*. doi: 10.1155/2023/8342104.
- [16] S. Nur Himawa and R. Sohiburoyyan, “Hyperparameter Tuning on Graph Neural Network for the Classification of SARS-CoV-2 Inhibitors,” 2023. [Online]. Available: <http://jurnal.polibatam.ac.id/index.php/JAIC>
- [17] X. Zeng, S. Wang, Y. Zhu, M. Xu, and Z. Zou, “A Knowledge Graph Convolutional Networks Method for Countryside Ecological Patterns Recommendation by Mining Geographical Features,” *ISPRS Int J Geoinf*, vol. 11, no. 12, Dec. 2022, doi: 10.3390/ijgi11120625.
- [18] O. Rainio, J. Teuho, and R. Klén, “Evaluation metrics and statistical tests for machine learning,” *Sci Rep*, vol. 14, no. 1, Dec. 2024, doi: 10.1038/s41598-024-56706-x.

- [19] T. Gu, H. Liang, C. Bin, and L. Chang, “Combining user-end and item-end knowledge graph learning for personalized recommendation,” *Journal of Intelligent and Fuzzy Systems*, vol. 40, no. 5, pp. 9213–9225, 2021, doi: 10.3233/JIFS-201635.
- [20] S. Siet, S. Peng, S. Ilkhomjon, M. Kang, and D. S. Park, “Enhancing Sequence Movie Recommendation System Using Deep Learning and KMeans,” *Applied Sciences (Switzerland)*, vol. 14, no. 6, Mar. 2024, doi: 10.3390/app14062505.
- [21] S. Subhan, D. L. Syarif, E. Widhihastuti, S. K. Rakainsa, M. Sam’an, and Y. N. Ifriza, “Improved recommender system using Neural Network Collaborative Filtering (NNCF) for E-commerce cosmetic product,” *Sinergi (Indonesia)*, vol. 29, no. 1, pp. 155–162, 2025, doi: 10.22441/sinergi.2025.1.014.
- [22] H. Yang, J. Li, and S. Jahng, “The Application of Knowledge Graph Convolutional Network-based Film and Television Interaction under Artificial Intelligence,” *IEEE Access*, 2024, doi: 10.1109/ACCESS.2024.3459448.
- [23] T. Al-shehari and R. A. Alsowail, “An insider data leakage detection using one-hot encoding, synthetic minority oversampling and machine learning techniques,” *Entropy*, vol. 23, no. 10, Oct. 2021, doi: 10.3390/e23101258.
- [24] Intan Permata and Esther Sorta Mauli Nababan, “Application Of Game Theory In Determining Optimum Marketing Strategy In Marketplace,” *JURNAL Riset RUMPUN MATEMATIKA DAN ILMU PENGETAHUAN ALAM*, vol. 2, no. 2, pp. 65–71, Jul. 2023, doi: 10.55606/jurrimipa.v2i2.1336.
- [25] C. Li, Y. Cao, Y. Zhu, D. Cheng, C. Li, and Y. Morimoto, “Ripple Knowledge Graph Convolutional Networks for Recommendation Systems,” *Machine Intelligence Research*, vol. 21, no. 3, pp. 481–494, Jun. 2024, doi: 10.1007/s11633-023-1440-x.